

Universidad Nacional Mayor de San Marcos
Universidad del Perú. Decana de América

Facultad de Ingeniería de Sistemas e Informática



Asignación Óptima de Recursos y Tareas en Metodologías Ágiles

Aplicación de Algoritmos Genéticos en Entornos SCRUM

Integrantes:

Salazar Garcia, Diego
Arias Chumpitaz, Giovanni
Arroyo Vasquez, Luis
Lavaud Guevara, Jean

Docente: Claudio Arango

**Lima, Perú
2025**

Resumen

Este trabajo presenta una propuesta de sistema inteligente para la asignación de tareas en equipos ágiles, utilizando un algoritmo genético multiobjetivo como núcleo de optimización. A través de una arquitectura cliente-servidor compuesta por un frontend en React y una API en Flask, el usuario puede configurar parámetros clave del algoritmo y visualizar los resultados de forma interactiva. La solución considera restricciones como habilidades requeridas, dependencias entre tareas, balance de carga y costos. Las pruebas realizadas con datos simulados permitieron validar el comportamiento del sistema ante distintas configuraciones, demostrando su utilidad como prueba de concepto aplicable a entornos reales de desarrollo ágil.

Palabras clave: *algoritmos genéticos, asignación de tareas, SCRUM, optimización, metodología ágil*

Abstract

This work presents an intelligent task assignment system for agile teams, based on a multi-objective genetic algorithm as the optimization core. Through a client-server architecture composed of a React frontend and a Flask API, users can configure key algorithm parameters and visualize the results interactively. The solution takes into account constraints such as required skills, task dependencies, workload balance, and cost. Experiments with simulated data validated the system's behavior under different configurations, demonstrating its potential as a proof of concept for real-world agile development environments.

Keywords: *genetic algorithms, task allocation, SCRUM, optimization, agile methodology*

1. Definición del Problema

En entornos ágiles como SCRUM, una de las dificultades más recurrentes es la asignación eficiente y equitativa de tareas entre los miembros del equipo de desarrollo. Esta asignación debe considerar múltiples factores simultáneamente, tales como la capacidad individual de cada desarrollador, la urgencia de las tareas, las dependencias entre actividades, las habilidades requeridas y los costos asociados al trabajo.

En la práctica, esta distribución suele realizarse de forma manual o semi-automática, lo que da lugar a diversos problemas: algunos desarrolladores terminan sobrecargados mientras otros están subutilizados, las tareas críticas o urgentes pueden quedar rezagadas, y las dependencias mal gestionadas provocan cuellos de botella en el flujo de trabajo del sprint. Además, si se ignora el nivel de habilidad requerido para cada tarea, pueden generarse asignaciones ineficientes que comprometen la calidad del producto o retrasan su entrega.

Este problema se vuelve aún más complejo al considerar que cada tarea puede requerir habilidades específicas en diferentes niveles, que la capacidad de los desarrolladores no siempre es uniforme (por ejemplo, algunos trabajan 30 horas por sprint, otros 40), y que el costo por hora de cada colaborador puede influir significativamente en el presupuesto del proyecto.

Frente a esta complejidad combinatoria y multifactorial, se requiere un enfoque de optimización inteligente que permita encontrar asignaciones que equilibren el uso de recursos, minimicen el tiempo total del proyecto, atiendan prioridades, y reduzcan costos. En este contexto, el uso de algoritmos genéticos se presenta como una alternativa viable para explorar eficientemente un espacio de soluciones altamente complejo.

2. Objetivos

Objetivo General

Diseñar e implementar un sistema de asignación automática y óptima de tareas en entornos ágiles tipo SCRUM, utilizando algoritmos genéticos que consideren múltiples restricciones reales como carga de trabajo, habilidades requeridas, prioridades, dependencias y costos.

Objetivos Específicos

- Balancear la carga de trabajo entre los desarrolladores, considerando sus capacidades horarias individuales.
- Asignar tareas a los desarrolladores cuyas habilidades coincidan en mayor medida con los requerimientos técnicos de cada tarea.

- Minimizar el tiempo total de ejecución del conjunto de tareas.
- Garantizar que las dependencias entre tareas se respeten en la planificación del sprint.
- Minimizar el costo total del proyecto considerando el costo por hora de cada desarrollador.
- Diseñar una función de evaluación que combine múltiples criterios mediante un sistema de pesos ajustables.

3. Alcance del Proyecto

Este trabajo aborda la implementación de un sistema de asignación automática de tareas en entornos SCRUM, considerando aspectos clave como capacidades horarias variables entre desarrolladores, habilidades técnicas diferenciadas, esfuerzo estimado de las tareas en horas, complejidad y prioridades. El sistema emplea un algoritmo genético como núcleo de optimización, buscando asignaciones que equilibren la carga, respeten dependencias y minimicen el costo total del proyecto.

El desarrollo se limita a la simulación de un equipo de desarrollo y no contempla integración directa con plataformas ágiles comerciales ni modelado de otros roles más allá de los desarrolladores. Tampoco se abordan requerimientos no funcionales como persistencia de datos, seguridad o despliegue en producción, ya que el enfoque es validar la viabilidad técnica del enfoque propuesto como un *proof of concept* adaptable a escenarios reales.

4. Marco Teórico

La gestión ágil de proyectos ha revolucionado la forma en que los equipos de desarrollo organizan su trabajo. En particular, el marco metodológico SCRUM propone una estructura iterativa e incremental para el desarrollo de productos, basada en ciclos de trabajo denominados *sprints* y en la colaboración constante entre los miembros del equipo (Schwaber & Sutherland, 2020). Uno de los principales desafíos dentro de SCRUM es la asignación eficiente de tareas a los desarrolladores, lo que implica considerar factores como la carga de trabajo, las habilidades requeridas, las prioridades y las dependencias técnicas entre actividades.

En entornos reales, dicha asignación suele realizarse manualmente por un *Scrum Master* o mediante juicio experto, lo cual puede introducir sesgos, sobrecarga en algunos miembros o secuencias ineficientes que retrasen el proyecto. Por ello, automatizar la asignación de tareas se vuelve una necesidad crítica para mejorar la eficiencia y la toma de decisiones en equipos ágiles (Masood et al., 2017). Como señala Maiello (2023), automatizar procesos dentro de metodologías ágiles puede representar una mejora significativa en términos de eficiencia y gestión operativa.

Una técnica destacada para abordar problemas de asignación con múltiples restricciones es el uso de **algoritmos genéticos** (AG). Estos forman parte de la computación evolutiva y se inspiran en los principios de la selección natural y la genética biológica propuestos por Darwin. Introducidos formalmente por Holland (1975), los algoritmos genéticos permiten buscar soluciones óptimas o casi óptimas en espacios de búsqueda complejos donde las técnicas tradicionales de optimización resultan ineficaces.

El funcionamiento de un algoritmo genético parte de una población inicial de soluciones aleatorias (denominadas *cromosomas*), que evolucionan mediante operadores como la selección, el cruce (*crossover*) y la mutación. Cada solución se evalúa mediante una función de *fitness*, la cual determina qué tan buena es en relación con el problema que se quiere resolver (Goldberg, 1989).

En el contexto de SCRUM, el cromosoma puede representar una asignación de tareas a desarrolladores. La función de fitness puede considerar criterios como el balance de carga, el cumplimiento de habilidades requeridas, el respeto por las dependencias y la minimización del costo total. Estudios como el de García Nájera y Gomez (2014) han demostrado que los algoritmos genéticos multiobjetivo son adecuados para resolver problemas complejos de planificación de proyectos de software, en los que se deben considerar simultáneamente restricciones como habilidades requeridas, precedencias entre tareas, tiempo de ejecución y costos.

A su vez, existen antecedentes de problemas similares en la literatura, como el problema de asignación de personal (Staff Assignment Problem, SAP), en el que se busca distribuir empleados a tareas bajo múltiples restricciones y objetivos simultáneos. Peters et al. (2019) abordaron un caso real de este tipo en una firma de servicios profesionales, proponiendo un algoritmo genético multiobjetivo que superó en eficiencia y calidad de soluciones a métodos clásicos como la programación entera mixta (MIP). Su enfoque demostró que los algoritmos evolutivos pueden ofrecer soluciones altamente competitivas en contextos reales, incluso bajo limitaciones de tiempo y condiciones operativas complejas.

En ese sentido, los algoritmos genéticos ofrecen una herramienta flexible y poderosa para resolver problemas de asignación en contextos ágiles, ya que permiten incorporar múltiples objetivos, adaptarse a restricciones cambiantes y explorar soluciones más allá de la intuición humana. Su uso en el presente proyecto permite simular un entorno realista y automatizado para la planificación eficiente de sprints en equipos SCRUM.

5. Metodología

La presente sección detalla la secuencia de desarrollo de la solución propuesta, partiendo del análisis del problema hasta su implementación como prueba de concepto (PoC). Se presenta además un flujograma del algoritmo, la arquitectura conceptual del sistema y los aspectos técnicos empleados en la validación de los resultados.

5.1. Etapas del Desarrollo

El desarrollo del sistema se dividió en las siguientes etapas:

1. **Análisis del problema:** Se identificaron las principales dificultades en la asignación de tareas en entornos ágiles, especialmente bajo restricciones de habilidades, dependencias y tiempos.
2. **Modelado:** Se definieron entidades clave como *tareas*, *desarrolladores*, sus atributos y relaciones. Se eligió el algoritmo genético como técnica de resolución.
3. **Diseño e implementación:** Se programó el algoritmo genético en Python, integrando módulos para evaluación de soluciones (fitness), selección por torneo, cruza (crossover) y mutación. También se desarrolló un backend con Flask y un frontend con React.
4. **Validación:** Se ejecutaron simulaciones con datos ficticios para analizar la efectividad del sistema bajo distintas configuraciones.




Figura 1: Resumen visual de las etapas del desarrollo del sistema.

5.2. Flujograma del Algoritmo

La Figura 2 muestra un flujograma general del proceso evolutivo del algoritmo genético implementado.

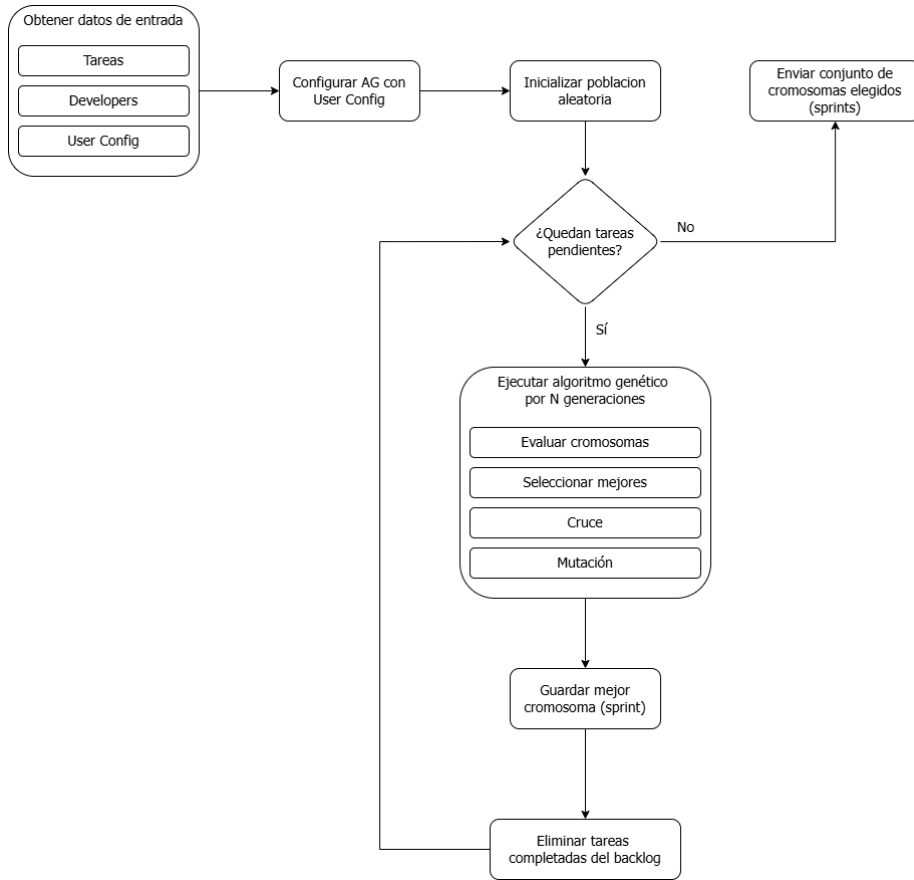


Figura 2: Flujograma general del algoritmo genético

5.3. Arquitectura del Sistema

La arquitectura general del sistema sigue un modelo cliente-servidor, compuesto por tres capas principales: el frontend, la API backend y el módulo del algoritmo genético. Cada componente cumple un rol específico y se comunican entre sí mediante peticiones HTTP.

- **Frontend:** Desarrollado con React y Vite, es la interfaz gráfica con la que el usuario interactúa para configurar parámetros del algoritmo y visualizar los resultados.
- **Backend/API:** Implementado con Flask en Python, actúa como intermediario entre el frontend y el algoritmo genético. Recibe las configuraciones del usuario y retorna los sprints generados.

- **Algoritmo Genético:** Encapsulado en el backend, este componente ejecuta la lógica evolutiva: inicialización de población, evaluación, selección, cruza, mutación y generación de nuevos sprints.

El siguiente esquema resume la interacción entre componentes:

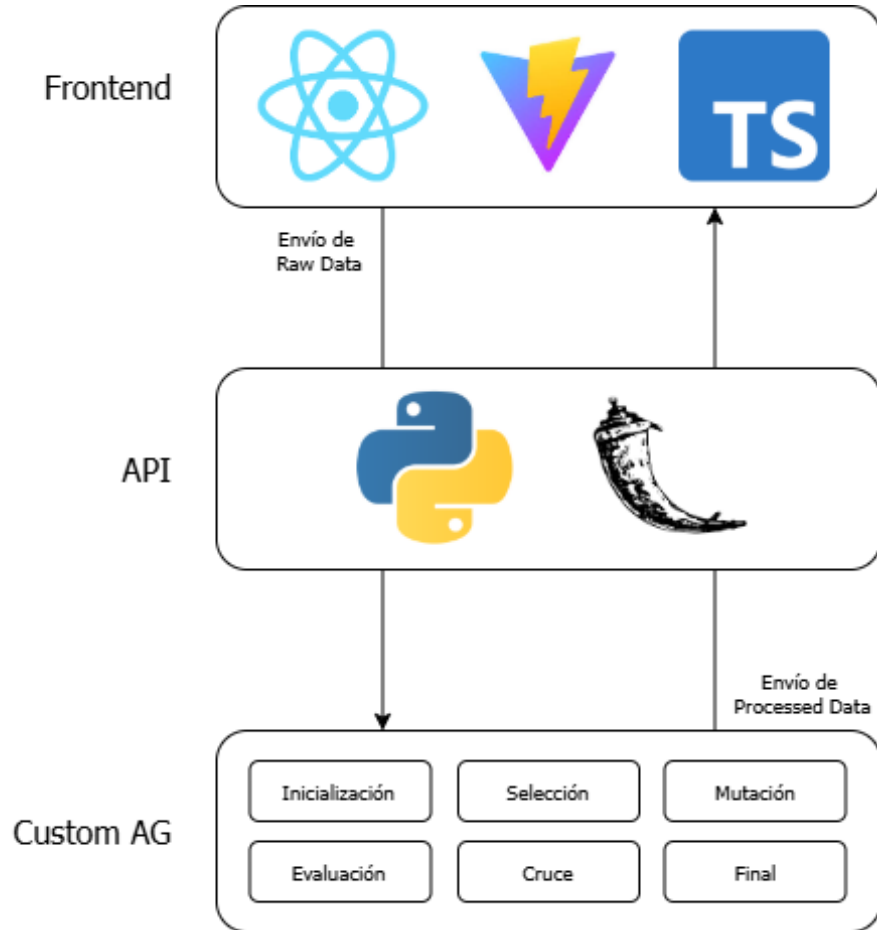


Figura 3: Arquitectura general del sistema.

5.4. Validación mediante Pruebas Simuladas

Para validar el sistema, se utilizaron conjuntos de datos representativos de un equipo ágil ficticio. Las simulaciones incluyeron tareas con diferentes niveles de prioridad, complejidad y dependencias, así como desarrolladores con habilidades y capacidades diversas.

Aunque los datos de tareas y desarrolladores eran estáticos (predefinidos en el frontend), se realizaron múltiples experimentos variando los parámetros configurables del algoritmo genético (como el tamaño de la población, la tasa de mutación, la cantidad de generaciones, los pesos de la función objetivo, etc.). Esto permitió analizar el comportamiento del sistema bajo distintas condiciones.

Además, el desarrollo del algoritmo se llevó a cabo de forma incremental y validada. Cada módulo del algoritmo genético —como la inicialización, evaluación, selección por torneo, cruza y mutación— fue implementado y probado por separado. Posteriormente, se integraron de forma progresiva hasta alcanzar la versión final con todas las restricciones consideradas: cumplimiento de dependencias, balance de carga, coincidencia de habilidades, y penalización por tareas no asignables o desarrolladores sobrecargados.

Las métricas utilizadas para evaluar la efectividad del sistema incluyeron:

- **Tiempo total estimado del sprint** (*makespan*).
- **Balance de carga** entre desarrolladores.
- **Coincidencia de habilidades** entre tareas y asignados.
- **Cumplimiento de dependencias** entre tareas.
- **Costo estimado** de asignación basado en las horas de cada desarrollador.

Los resultados obtenidos demuestran que el sistema logra generar sprints viables y balanceados en tiempos razonables, y que responde de manera coherente ante variaciones en los parámetros evolutivos.

5.5. Herramientas y Tecnologías Utilizadas

El desarrollo del sistema se apoyó en una serie de herramientas y tecnologías modernas que facilitaron la implementación modular y colaborativa del proyecto. A continuación se detallan:

- **Lenguajes de programación:** Python para el backend y JavaScript/TypeScript para el frontend.
- **Frameworks y entornos:**
 - *Flask* para la creación de la API REST.
 - *React* y *Vite* para el desarrollo del frontend, con enrutamiento gestionado mediante React Router.
- **Control de versiones:** Git y GitHub fueron utilizados para el seguimiento del desarrollo y la colaboración en equipo.
- **Entorno de desarrollo:** Visual Studio Code fue el editor principal, junto con extensiones y herramientas como Thunder Client para pruebas de API.
- **Diagramación:** Draw.io fue empleado para la elaboración de flujogramas y diagramas de arquitectura.
- **Documentación:** La redacción del informe se realizó utilizando LaTeX, empleando una plantilla compartida mediante GitHub.

6. Propuesta de Solución

La propuesta presentada consiste en un sistema interactivo orientado a entornos ágiles, que permite optimizar la asignación de tareas dentro de un equipo de desarrollo mediante el uso de un algoritmo genético multiobjetivo. La solución busca balancear la carga de trabajo, minimizar el tiempo total de ejecución y considerar factores clave como dependencias, habilidades requeridas y costos asociados.

El sistema se estructura en torno a una arquitectura modular que separa claramente la interfaz de usuario, la lógica de negocio y el motor de optimización. Esta separación permite una interacción clara y eficiente con el usuario, al mismo tiempo que encapsula la complejidad de la heurística evolutiva implementada.

En las siguientes subsecciones se detalla el modelo general del sistema, el diseño del algoritmo genético propuesto, y la forma en que los componentes se integran para generar una solución viable y extensible al problema de asignación de tareas.

6.1. Modelo General del Sistema

Como se representó anteriormente en la Figura 3, el sistema está compuesto por tres componentes principales: **Interfaz Gráfica**, **API** y **Núcleo de Optimización**.

- **Interfaz Gráfica:** Permite al usuario visualizar los resultados y configurar parámetros clave del algoritmo genético, como el tamaño de la población, número de generaciones, tasas de cruce y mutación, tamaño del torneo y los pesos de la función objetivo.
- **API:** Recibe las configuraciones del usuario y los datos estáticos de tareas y desarrolladores. Actúa como intermediario entre la interfaz gráfica y el núcleo del algoritmo, enviando y recibiendo información a través de endpoints definidos en Flask.
- **Núcleo de Optimización:** Implementado en Python, este módulo contiene la lógica completa del algoritmo genético. Se encarga de generar soluciones viables y optimizadas para la asignación de tareas, respetando restricciones de dependencias, habilidades, tiempos y costos.

Esta aproximación cliente-servidor con separación clara entre capas permite al usuario interactuar de forma sencilla con la aplicación, facilitando la configuración de parámetros y la visualización de resultados, todo mientras se mantiene encapsulada la complejidad interna del algoritmo genético multiobjetivo para la optimización de la asignación de tareas.

6.2. Algoritmo Genético Propuesto

El núcleo del sistema implementa un **algoritmo genético multiobjetivo** para resolver el problema de asignación de tareas bajo múltiples restricciones prácticas. Esta técnica de optimización evolutiva busca simultáneamente minimizar o balancear varios factores conflictivos mediante una *función de evaluación compuesta*, lo cual distingue este enfoque de soluciones más simples o unidimensionales.

Como ya fue ilustrado en la Figura 2, el algoritmo parte de una población aleatoria de asignaciones. A través de ciclos generacionales, se aplican los operadores clásicos de selección, cruce y mutación, buscando mejorar progresivamente la calidad de las soluciones candidatas.

- **Función de evaluación compuesta (multiobjetivo):** La aptitud de cada cromosoma se determina mediante una combinación ponderada de múltiples criterios:
 - **Makespan:** duración total del sprint.
 - **Balance de carga:** distribución equitativa del esfuerzo.
 - **Habilidades:** ajuste entre habilidades requeridas y ofrecidas.
 - **Costo estimado:** según tarifas por hora de cada desarrollador.

Los pesos asignados a cada uno de estos criterios pueden ser definidos por el usuario desde la interfaz del sistema. Este aspecto se detalla más adelante en la Sección 6.4.

- **Verificación previa y caché:** Se implementa una caché que almacena los valores de fitness ya evaluados para evitar recomputaciones innecesarias. Asimismo, las tareas se ordenan topológicamente antes del proceso evolutivo para asegurar que las dependencias entre ellas se respeten desde el inicio.
- **Operadores genéticos personalizados:** Se adaptaron los operadores clásicos del algoritmo genético para cumplir con las restricciones específicas del problema:
 - **Selección por torneo:** elección competitiva aleatoria.
 - **Cruce por segmentos:** combina parcialmente asignaciones entre padres.
 - **Mutación por reasignación:** cambio aleatorio de tarea.
 - **Corrección posterior:** validación de soluciones generadas.
 - **Elitismo parcial:** preserva el mejor individuo en cada generación.

Estos mecanismos se describen en detalle en la Sección 6.5.

- **Mecanismo de paciencia (estancamiento):** Si durante un número consecutivo de generaciones no se encuentra una mejor solución, el algoritmo se detiene anticipadamente, optimizando el tiempo de ejecución sin comprometer la calidad.

Este enfoque multiobjetivo permite una exploración equilibrada del espacio de soluciones, adaptándose a prioridades definidas por el usuario y garantizando asignaciones válidas, eficientes y costo-efectivas de las tareas disponibles.

6.3. Representación de Soluciones

En el contexto del algoritmo genético propuesto, cada solución candidata —también llamada cromosoma— representa una asignación completa de tareas a desarrolladores para un sprint específico. Esta asignación se codifica como una lista ordenada de identificadores de desarrolladores, donde la posición de cada elemento corresponde a una tarea según un orden topológico que respeta las dependencias del proyecto.

Ejemplo de representación: Supóngase un conjunto de cuatro tareas ordenadas como $[T_0, T_1, T_2, T_3]$ y un cromosoma dado por la secuencia $[2, 1, 1, 3]$. Esto implica que:

- La tarea T_0 se asigna al desarrollador con ID 2.
- La tarea T_1 se asigna al desarrollador con ID 1.
- La tarea T_2 también se asigna al desarrollador 1.
- La tarea T_3 se asigna al desarrollador con ID 3.

Dado que no todas las tareas pueden resolverse en un solo sprint —debido a restricciones de tiempo o dependencias—, el algoritmo aplica esta lógica de forma iterativa. Es decir, genera una secuencia de cromosomas (uno por sprint) hasta que se completa la asignación de todas las tareas del backlog. Cada uno de estos cromosomas constituye una solución parcial, y el conjunto completo representa la solución total del sistema.

Una forma simple de visualizar esta asignación es mediante una tabla que agrupe las tareas por sprint, detallando a qué desarrollador se asignó cada una de ellas y los tiempos estimados de ejecución.

Sprint	Tarea	Desarrollador	Inicio (h)	Fin (h)
1	T0	Dev 2	0	3
1	T1	Dev 1	0	5
1	T2	Dev 1	5	10
1	T3	Dev 3	0	4
2	T4	Dev 2	0	4
2	T5	Dev 1	0	3
2	T6	Dev 3	0	2

De esta forma, podemos ver claramente tanto la estructura de un cromosoma individual —con sus tareas asignadas, desarrolladores responsables y tiempos estimados— como el conjunto completo de cromosomas que, distribuidos por sprint, conforman una solución integral.

Este conjunto final de cromosomas constituye la salida principal del algoritmo, y será posteriormente interpretado por la interfaz del usuario, que se encargará de presentarlo de forma comprensible y útil para el usuario final.

6.4. Evaluación de Soluciones (Función Objetivo)

La calidad de cada solución candidata —representada por un cromosoma— es evaluada mediante una función objetivo compuesta que pondera múltiples criterios relevantes para la planificación ágil de proyectos. Esta función busca minimizar los siguientes aspectos:

- **Makespan (50 %)**: tiempo total requerido para completar todas las tareas asignadas, considerando las dependencias y la disponibilidad de cada desarrollador.
- **Varianza de carga (25 %)**: medida de desequilibrio en la cantidad de trabajo distribuido entre desarrolladores. Cuanto menor sea, más balanceado es el plan.
- **Coincidencia de habilidades (20 %)**: penalización proporcional a la diferencia entre los niveles de habilidad requeridos por una tarea y los ofrecidos por el desarrollador asignado.
- **Costo total (5 %)**: estimado en función de las horas trabajadas por cada desarrollador y su tarifa horaria.

Todos estos valores son combinados mediante una fórmula ponderada de la siguiente forma:

$$\text{Fitness} = w_1 \cdot \text{Makespan} + w_2 \cdot \text{Varianza} + w_3 \cdot \text{SkillGap} + w_4 \cdot \text{Costo}$$

Donde los pesos (w_1, w_2, w_3, w_4) son definidos por el usuario a través de la interfaz del sistema y, por defecto, corresponden a (0,5, 0,25, 0,2, 0,05).

Además, si una solución incumple restricciones críticas —como exceder la capacidad horaria de un desarrollador o asignar tareas con brechas de habilidad excesivas— se le asigna automáticamente una penalización severa definida como `BIG_PENALTY`. Esto permite descartar de forma eficiente los cromosomas inviables sin necesidad de mantenerlos durante el proceso evolutivo.

Pseudocódigo de evaluación:

```
function evaluate_chromosome(chromosome):  
    asignar tareas a desarrolladores según cromosoma  
    calcular makespan total  
    calcular varianza de carga entre desarrolladores  
    calcular penalización por brechas de habilidades  
    calcular costo total estimado  
  
    if capacidad excedida o penalización muy alta:  
        return BIG_PENALTY  
  
    return w1*makespan + w2*varianza + w3*penalización + w4*costo
```

Gracias a esta evaluación compuesta, el algoritmo puede priorizar soluciones más equilibradas y alineadas con los objetivos del sistema, al considerar simultáneamente múltiples criterios derivados de las restricciones del problema.

Esta función actúa como el eje central del proceso evolutivo, guiando la búsqueda hacia asignaciones óptimas dentro de un espacio de soluciones complejo y condicionado por las tareas y los perfiles de los desarrolladores disponibles.

6.5. Operadores Genéticos Personalizados

Una vez evaluadas las soluciones candidatas mediante la función objetivo, el algoritmo debe decidir cuáles de ellas continuarán participando en el proceso evolutivo. Para ello, se emplean los operadores genéticos clásicos propios de esta familia de algoritmos, como la selección, el cruce y la mutación, que permiten generar nuevas combinaciones de asignaciones a partir de las existentes.

En nuestro contexto particular, dichos operadores fueron adaptados para respetar las restricciones del problema, evitando asignaciones inválidas y promoviendo la diversidad sin comprometer la validez de las soluciones. Esto dio lugar a un conjunto de operadores genéticos personalizados, cuya función es guiar de forma eficiente la exploración del espacio de soluciones, favoreciendo la mejora progresiva de la población en cada generación.

A continuación se detallan los operadores personalizados implementados en el sistema:

- **Selección por torneo:** Se elige aleatoriamente un subconjunto de soluciones candidatas y se selecciona la mejor entre ellas. Este método favorece un equilibrio entre explotación y diversidad, evitando la convergencia prematura a soluciones subóptimas.
- **Cruce por segmentos:** A partir de dos soluciones padres, se toma un segmento de asignaciones de uno de ellos y se completa la solución con los valores del otro, cuidando no violar restricciones como dependencias o exceso de carga por desarrollador.
- **Mutación por reasignación:** Con una baja probabilidad, se modifica la asignación de una tarea a otro desarrollador válido. Esta operación introduce variación genética y ayuda a explorar regiones no visitadas del espacio de búsqueda.
- **Corrección postoperadores:** Tras aplicar cruce o mutación, se verifica que la solución resultante sea válida. Esto incluye evitar duplicaciones indebidas, respetar capacidades, y garantizar el cumplimiento de las dependencias entre tareas.
- **Elitismo parcial:** En cada generación, se preserva el mejor cromosoma encontrado hasta el momento, garantizando que los avances evolutivos no se pierdan. Esta élite se mantiene limitada para no comprometer la diversidad genética de la población.

Gracias a estos operadores personalizados, el algoritmo puede generar soluciones viables incluso en escenarios altamente restringidos, manteniendo un equilibrio entre exploración y explotación durante todo el proceso evolutivo.

6.6. Interacción con la Interfaz Web

El sistema incluye una interfaz web intuitiva que permite al usuario gestionar todo el flujo de trabajo: carga de datos, configuración del algoritmo, ejecución del proceso evolutivo y visualización de resultados optimizados.

6.6.1. Visualización de Datos de Tareas y Desarrolladores

La interfaz incluye secciones dedicadas para consultar las tareas y desarrolladores definidos en el sistema. Estas páginas permiten al usuario revisar propiedades clave como esfuerzo estimado, habilidades requeridas, prioridades, capacidades y costos por hora.

Si bien actualmente no se admite la carga dinámica de datos desde la interfaz, el sistema trabaja con un conjunto representativo de tareas y desarrolladores de prueba.

Este conjunto es suficiente para validar el funcionamiento del algoritmo y visualizar sus resultados en un entorno controlado.

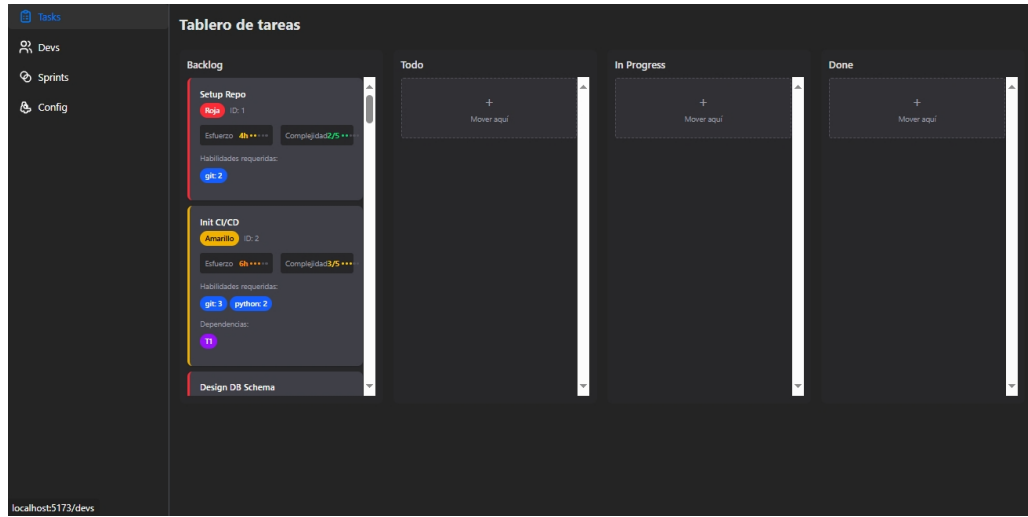


Figura 4: Pestaña de tablero de tareas disponibles.

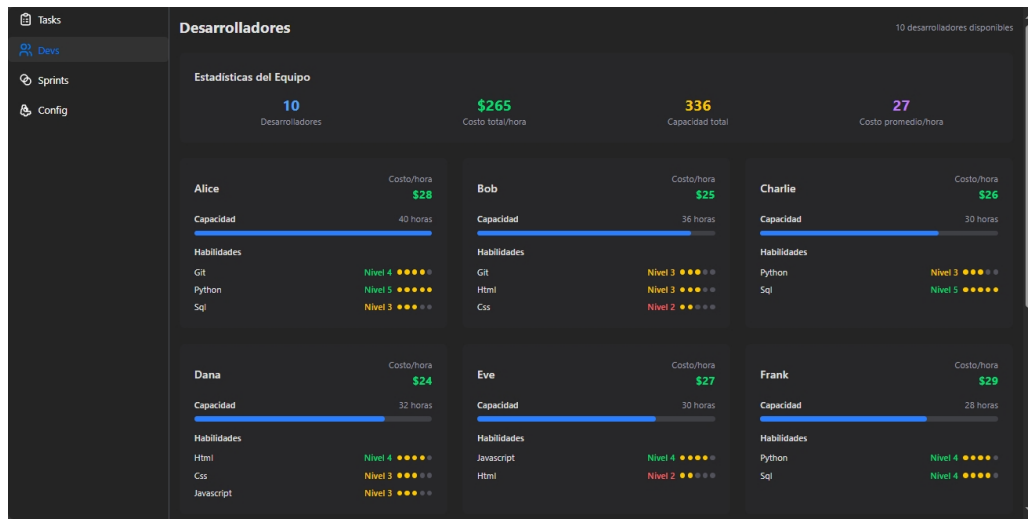


Figura 5: Pestaña de desarrolladores definidos.

6.6.2. Configuración de Parámetros del Algoritmo

La interfaz permite ajustar los parámetros clave que gobiernan el comportamiento del algoritmo genético. Estos incluyen el tamaño de la población, el número máximo de generaciones, las tasas de cruce y mutación, el tamaño del torneo de selección, y los pesos asignados a cada uno de los criterios de evaluación.

Esta configuración flexible permite experimentar con distintas estrategias evolutivas según las necesidades del usuario.

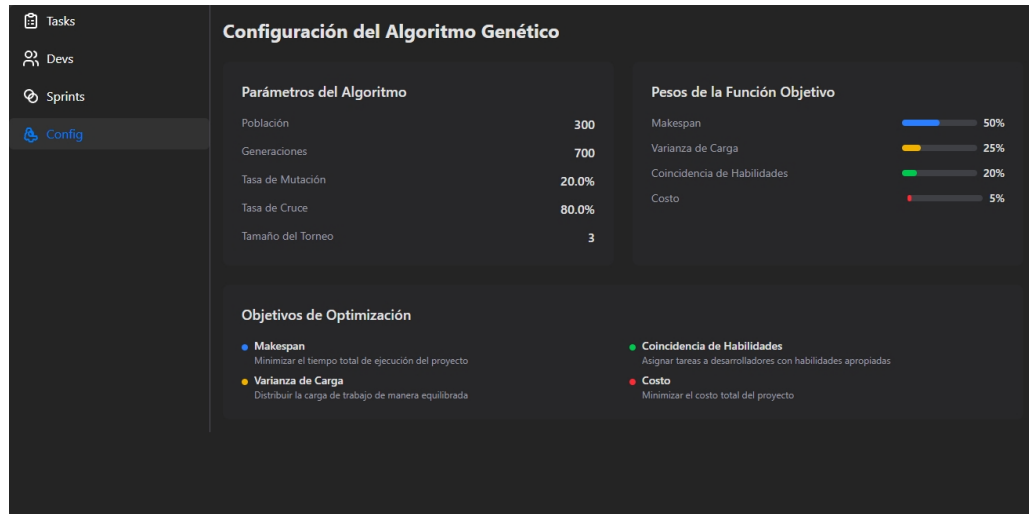


Figura 6: Panel de configuración del algoritmo genético.

6.6.3. Ejecución del Algoritmo y Visualización de Resultados

Una vez definidos los datos y parámetros, el usuario puede ejecutar el algoritmo desde la sección correspondiente. El sistema procesa las asignaciones y genera uno o varios sprints optimizados que se presentan visualmente.

Cada resultado muestra qué tareas fueron asignadas a cada desarrollador, la duración del sprint (makespan) y la prioridad de las tareas incluidas, permitiendo evaluar rápidamente la calidad de la solución generada.

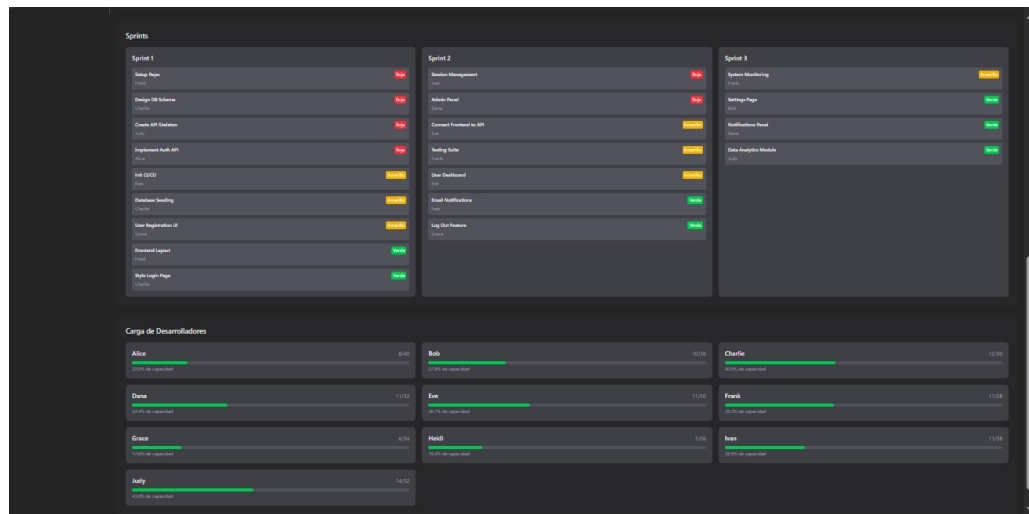


Figura 7: Visualización de los sprints generados por el algoritmo.

Cierre del Proceso

Con esta secuencia completa —desde la visualización de los datos base, pasando por la configuración personalizada del algoritmo, hasta la ejecución del proceso evolutivo y la interpretación de sus resultados— se cubre todo el ciclo de uso del sistema propuesto.

Este flujo integral permite al usuario obtener soluciones optimizadas de forma accesible y comprensible, facilitando así la toma de decisiones informadas dentro de contextos reales de planificación y asignación de tareas.

7. Conclusiones

Este trabajo ha demostrado que es posible construir un sistema automatizado capaz de resolver la asignación de tareas en entornos ágiles SCRUM mediante un algoritmo genético multiobjetivo, integrando simultáneamente múltiples restricciones prácticas como habilidades requeridas, dependencias entre tareas, capacidades individuales y costos. La solución no solo logra generar asignaciones eficientes, sino que también respeta principios clave de metodologías ágiles como la iteración progresiva y la transparencia del proceso.

La implementación completa, compuesta por una interfaz gráfica en React, una API desarrollada en Flask y un motor de optimización en Python, valida que un enfoque modular y desacoplado es viable incluso en proyectos académicos, sentando las bases para futuras integraciones más complejas. Este diseño permitió realizar validaciones constantes a lo largo del desarrollo, ajustando y refinando componentes del algoritmo hasta alcanzar una versión estable y funcional.

Uno de los principales aprendizajes fue comprobar que, con una buena representación del problema y operadores genéticos bien diseñados, es posible obtener soluciones de alta calidad incluso en un dominio con restricciones duras y objetivos conflictivos. También se confirmó que la exposición clara de los parámetros de configuración al usuario (como tasas de cruce, mutación o pesos de la función objetivo) agrega valor al sistema, haciéndolo más flexible y comprensible.

Si bien existen limitaciones como el uso de datos estáticos para tareas y desarrolladores, estas no comprometen el valor de la propuesta como prueba de concepto sólida. El sistema desarrollado no solo cumple su objetivo académico, sino que representa un punto de partida válido para aplicaciones reales en entornos empresariales o educativos donde se requiere automatizar la gestión de tareas de forma inteligente.

8. Recomendaciones

Una de las principales recomendaciones es extender la solución para permitir la carga dinámica de datos por parte del usuario. Actualmente, las tareas y desarro-

lladores están predefinidos en el sistema, lo cual limita su flexibilidad. Incorporar formularios o integración con bases de datos permitiría simular escenarios reales y adaptar el sistema a contextos específicos de empresas o instituciones educativas. Esta mejora también facilitaría la validación del algoritmo con conjuntos de datos reales y facilitaría su adopción práctica.

Adicionalmente, se sugiere mejorar las capacidades de visualización del sistema. Aunque la interfaz actual permite observar resultados básicos, sería conveniente integrar herramientas interactivas como gráficos de Gantt, dashboards con métricas de rendimiento o incluso simulaciones visuales del avance del sprint. Estas mejoras no solo enriquecerían la experiencia del usuario, sino que también permitirían tomar decisiones más informadas a partir de los resultados generados por el algoritmo.

Finalmente, desde una perspectiva investigativa, se recomienda experimentar con variantes del algoritmo genético e incluso explorar enfoques híbridos, como algoritmos meméticos o combinaciones con reglas heurísticas extraídas de prácticas ágiles reales. También sería interesante aplicar el sistema en casos de estudio reales, con equipos de desarrollo reales, para evaluar no solo métricas técnicas como el makespan o la varianza de carga, sino también el impacto en la motivación, percepción de equidad y productividad del equipo.

Bibliografía

- García Nájera, A., & Gomez, M. (2014). A Multi-Objective Genetic Algorithm for the Software Project Scheduling Problem. *Lecture Notes in Computer Science*, 8857. https://doi.org/10.1007/978-3-319-13650-9_2
- Goldberg, D. E. (1989). *Genetic Algorithms in Search, Optimization and Machine Learning*. Addison-Wesley.
- Holland, J. H. (1975). *Adaptation in Natural and Artificial Systems*. University of Michigan Press.
- Maiello, A. S. (2023). Task Optimization utilizing Digital Transformation Concepts-Automation Project Execution via AGILE Methodology.
- Masood, Z., Hoda, R., & Blincoe, K. (2017). Exploring workflow mechanisms and task allocation strategies in agile software teams. *Agile Processes in Software Engineering and Extreme Programming: 18th International Conference, XP 2017, Cologne, Germany, May 22-26, 2017, Proceedings 18*, 267-273.
- Peters, J., Stephan, D., Amon, I., Gawendowicz, H., Lischoid, J., Salabarria, L., Umland, J., Werner, F., Krejca, M. S., Rothenberger, R., Kötzing, T., & Friedrich, T. (2019). Mixed Integer Programming versus Evolutionary Computation for Optimizing a Hard Real-World Staff Assignment Problem. *Proceedings of the International Conference on Automated Planning and Scheduling (ICAPS)*, 29(1), 541-554. <https://doi.org/10.1609/icaps.v29i1.3521>
- Schwaber, K., & Sutherland, J. (2020). The Scrum Guide. <https://scrumguides.org/scrum-guide.html>